빅데이터 프로그래밍 1 팀프로젝트

:몬테카를로 시뮬레이션을 활용한 학생 과락 리스크 분석

14 조

2022102991 장성빈

2024101660 신유빈

2025102741 진익서

2025102752 최영민

요약

본 연구는 전통적인 다중회귀분석(OLS)이 제시하는 '단일 평균 예측'의 한계를 극복하고, 학생들의 학업 성취도에 내재된 변동성과 '과락 리스크'를 정량적으로 분석하기 위해 몬테카를로 시뮬레이션을 사용하였다. 분석을 위해 포르투갈 학교의 수학 성취도 데이터셋(UCI)을 활용하였다. 결시생으로 인한 구조적 0 점을 제외한 유효 데이터를 바탕으로 주당 공부시간, 결석 횟수, 1 학기 성적(G1)을 주요 독립변수로 설정하였다.

몬테카를로 시뮬레이션 구현과정에서는 머신러닝 라이브러리에 의존하지 않고, 기초 라이브러리만을 활용하여 OLS 정규방정식과 숄레스키 분해(Cholesky Decomposition)를 직접 수학적으로 구현하였다. "학습 부족과 잦은 결석"을 가정한 고위험군 시나리오를 OLS 로 분석했을 때, '10.29 점'이라는 예측치를 구했다. 이는 우리가 세운 8 점의 과락기준보다 높은 점수였다. 그러나 숄레스키 분해와 시험 당일의 불확실성까지 포함한 몬테카를로 시뮬레이션은 약 10,000 번의 반복 실험을 통해 24.14%의 숨겨진 잠재적 과락 확률을 발견하였다. 다중회귀분석의 단일 예측치는 발견하지 못한 약 25%의 리스크를 발견할 수 있었다.

결과적으로 본 연구는 회귀분석이 놓치기 쉬운 통계적 '꼬리 위험(Tail Risk)'을 정량적인 확률 분포로 시각화하는 데 성공했다. 이러한 방법론이 향후 다변량 공분산 모형 고도화 및 실시간 리스크 대시보드를 통한 학업 위기 조기경보 시스템 등 교육 현장의 선제적 개입 정책에 어떻게 기여할 수 있는지 실무적 시사점을 제공한다.

목차

1. 서론

- 1.1. 연구 배경 및 목적
- 1.2. 몬테카를로 시뮬레이션의 개념 및 적용 타당성

2. 데이터 수집 및 전처리

- 2.1. 분석 데이터셋 및 변수 선정
- 2.2. 결측치 및 이상치 처리
- 2.3. 고위험군 시나리오 설정

3. 분석 방법론 및 핵심 코드 구현

- 3.1. OLS 정규방정식 수동 구현 및 해석
- 3.2. 숄레스키 분해와 공분산 난수 생성
- 3.3. 시뮬레이션 루프 및 시험 당일의 변동성 주입
- 3.4. 과락 확률 계산 및 대수의 법칙 검증

4. 시각화 및 결과 해석

- 4.1. 성적 분포 히스토그램
- 4.2. 대수의 법칙 수렴 시각화

5. 결론 및 제언

- **5.1. 핵심 결론 및 시사점**
- **5.2. 연구의 한계점**
- **5.3. 향후 확장 방향 및 실무적 의의**

6. 참고문헌

1. 서론

1.1. 연구 배경 및 목적

학생의 학업 성취도는 단순히 투입된 학습 시간이나 출석 횟수에 의해 기계적으로 결정되지 않는다. 교육 데이터는 학생의 심리, 환경, 시험 당일의 컨디션, 문제 난이도 등 다양한 확률적 요인과 불확실성의 영향을 크게 받는다.[1] 그러나 기존의 전통적인 OL(최소제곱법)을 활용한 회귀분석은 여러 독립변수를 통해 단 하나의 '단일 예측 점수(평균치)'만을 도출한다는 치명적인 한계가 있다.

예를 들어, "주 2 시간 미만 공부하고 결석을 30 번 한 학생의 평균 예상 점수는 10 점입니다."라고 예측하는 식이다. 물론 이러한 단일 예측치가 실제로 맞을 수도 있다. 하지만 현실에서는 똑같은 악조건 속에서도 운이 좋아 12 점을 받아 통과하는 학생이 있는 반면, 7 점을 받아 과락(낙제)하는 학생도 존재한다.(8 점을 과락 기준 점수라고 가정했을 시) 회귀분석의 단일 수치는 이러한 변동성을 완전히 무시하기 때문에, 실제 교육 현장에서 가장 경계해야 할 '과락 리스크'를 과소평가하게 만든다. 따라서 숨어 있는 확률을 가장 잘 시각화하는 알고리즘이 '몬테카를로 시뮬레이션'이기에, 이번 프로젝트의 주 방향으로 설정하였다.

프로젝트의 목적은 전통적인 다중회귀분석이 제시하는 '단일 평균 예측의 함정'을 지적하고, 이를 극복하기 위한 대안으로 몬테카를로 시뮬레이션(Monte Carlo Simulation)을 도입하는 것이다. 난수를 활용한 수만 번의 반복 실험을 통해 현실의 불확실성을 수치화하고, 특정 고위험군(학습 부족 및 잦은 결석) 학생에게 숨겨져 있는 '과락 확률'을 정량적인 확률 분포로 시각화하여 증명하고자 한다.

1.2. 몬테카를로 시뮬레이션의 개념 및 적용 타당성

몬테카를로 시뮬레이션의 실제 정의에 대해 제대로 설명해보려 한다. 이는 모나코의 카지노 도시 '몬테카를로'에서 유래한 이름으로, 불확실성을 수만 번의 난수 실험으로 변환해 숨겨진 리스크를 확률로 시각화하는 기법이다. 쉽게 예를 들어보자. 동전을 10 번 던지면 앞면 비율이 50%이론적 확률)에서 크게 벗어날 수 있지만, 10,000 번을 던지면 대수의 법칙에 의해 50%에 수렴하게 된다. 이와 같은 개념을 이용한 알고리즘이다.

이를 본 분석에 적용하면, 특정 악조건(예: 학습 시간 급감, 출석률 저하)에 처한 가상의 학생 10,000 명을 컴퓨터로 생성하여 모의고사를 치르게 하는 것과 같다. 이를 통해 단일한 예측 점수를 내놓고 끝나는 것이 아니라, 성적이 어떻게 분포하는지를 확인하고 최종적으로 "과락이라는 최악의 결과가 발생할 확률"을 명확한 퍼센트(%)로 도출할 수 있다.

2. 데이터 수집 및 전처리

2.1. 분석 데이터셋 및 변수 선정

본 분석에서는 포르투갈 고등학교 학생들의 수학 과목 성취도를 담은 'UCI Student Performance Dataset (Cortez & Silva, 2008)'을 활용하였다. 다중회귀분석 및 시뮬레이션의 수행을 위해 사용할 독립변수와 종속변수를 다음과 같이 선정하였다.

- 독립변수 (X):

- studytime: 주당 공부시간 (1: <2 시간, 2: 2~5 시간, 3: 5~10 시간, 4: >10 시간)
- absences: 결석 횟수 (0~93 회)
- G1: 1 학기 성적 (0~20 점)

-종속변수 (y): G3 (최종 성적, 0~20 점)

독립변수는 총 세 가지를 사용하였다. 주당학습시간의 데이터인 'studytime'은 범주형 데이터로 이루어져 있었다. 결석횟수를 나타내는 'absences' 같은 경우, 수치가 0~93 사이였다. 따라서 약 0~100 사이에 있다고 기준을 삼아 활용하였다. 마지막 독립변수인 G1 의 경우, 이전 시험 성적이다. 데이터 속, G2 라는 시험성적도 존재하였다. 그러나 우리가 관찰하려는 종속변수 G3 과 시간 차가 얼마 나지 않아, 종속변수와의 관계가 너무 강하다고 판단했다. 이는 우리가 보려는 독립변수의 제대로된 영향력을 도출할 수 없다고 판단하여, G2 데이터 대신 G1 데이터를 사용하였다.

또한 시험 성적을 독립변수에 포함한 이유는, 단순히 공부 시간과 출석률만 변수로 넣을 경우 컴퓨터가 개별 학생의 기초 학력을 무시하고 모두가 비슷하게 실패할 것이라 단순 예측하는 것을 방지하기 위함이다. G1 을 추가함으로써 훨씬 현실적이고 정교한 시뮬레이션이 가능해진다.

제일 중요한 변수인 G3 는 바로 최종성적 데이터이다. 후술할 고위험군 시나리오의 학생들이 최종성적을 몇 점 받을지 예상하여 과락 여부를 분석하였다.

포르투갈 학교의 시험 성적은 20 점 만점을 기준으로 하고 있다. 우리나라의 경우, 시험 만점을 100 점으로 두고 있으나, 해당 데이터는 이와 달랐다. 우리나라 기준과 맞추어도 좋으나, 해당 데이터의 기준을 그대로 사용하기로 하였다.

2.2. 결측치 및 이상치 처리

해당 데이터를 살펴보던 중, 종속변수인 G3 가 0 점인 데이터들이 다수 발견되었다. 이들은 1 학기 성적(G1)이 정상적임에도 불구하고 최종 성적이 0 점으로 기록된 사례들이었다. 이는 정상적으로 시험을 치러 0 점을 받은 것이 아닌, '시험 결시 및 중도

포기'로 인해 발생한 구조적 0 점으로 판단하였다. '끝까지 시험을 치른 정상적인 학생이 겪을 수 있는 성적 하락 리스크'를 분석하는 것이 목표이다. 따라서 회귀 모델의 왜곡을 막고 신뢰도를 높이기 위해, G3 가 0 점인 결시생 데이터를 전처리 과정에서 제거하였다. 그 결과 총 357 명의 순수 유효 데이터를 확보하였다.

2.3. 고위험군 시나리오 설정

몬테카를로 시뮬레이션의 대상이 될 가상의 '고위험군 학생' 시나리오를 다음과 같이 설정하였다.

- 공부시간 (`scenario_studytime`) = 1.5: 본 데이터의 학습 시간은 범주형이다. 주당 5 시간 미만이라는 폭넓은 조건을 수학적 모형에 반영하기 위해 1 단계(<2 시간)와 2 단계(2~5 시간)의 중간값인 1.5 를 부여하였다.
- 결석 횟수 (`scenario_absences`) = 30: 출석률이 70% 수준으로 저조해진 상황을 가정하였다.
- 1 학기 성적 (`scenario_G1`) = 11: 실제 데이터의 평균값이다. 이전 시험에서 평균 수준의 성적을 받아 무난하게 과락을 면했던 평범한 학생이, 그 후 공부를 안 하고 결석을 일삼는 악조건에 빠졌을 때, 성적이 어떻게 곤두박질치는지 가장 극적이고 객관적으로 보여주기 위한 역할을 한다.
- 과락 기준 (`fail_threshold`) = 8: 20 점 만점 기준 40% 미만을 과락으로 규정하였다.

3. 분석 방법론 및 파이썬 코드 구현

본 분석에서 `scikit-learn`과 같은 머신러닝 라이브러리에 의존하여 결과를 도출하는 것을 배제하였다. 대신 `pandas`, `numpy`, `matplotlib` 등과 같은 기초

라이브러리만을 활용하였다. 이를 통해 OLS 정규방정식과 Cholesky 분해, 몬테카를로 난수 생성을 수학적 수식으로 진행하였다.

코딩 과정 중 수학적 행렬 연산 공식이나 어려운 부분이 다수 존재했다. 본 수업에서 배운 파이썬 기초 지식으로는 구현이 어려웠다. 따라서 해당 과정에서는 생성형 AI 를 참고하여 분석을 진행하였다.

3.1. OLS 정규방정식 수동 구현 및 해석

다중선형회귀의 최적 가중치 행렬인 β 를 구하기 위해 정규방정식 공식을 사용하였다. 공식은 $\beta = (X^T X)^{-1} X^T y$ 이며, 모델의 절편(Intercept)을 산출하기 위해 독립변수 행렬 X의 맨 앞에 1 로 이루어진 상수를 결합한 편향 열을 의도적으로 삽입하였다.

```
1 # 1. 행렬 연산을 위해 데이터프레임을 Numpy 배열로 변환
2 X_values = X.values
3 y_values = y.values
4
5 # 2. 절편(Intercept, 베타0)을 구하기 위해 X 행렬의 맨 앞에 1로 채워진 열(Column) 추가
6 X_matrix = np.c_[np.ones((len(X_values), 1)), X_values]
```

- [핵심 코드 1] 정규방정식을 이용한 회귀 계수(β) 직접 산출

  np.linalg.inv() 함수는 행렬의 역행렬을 계산하며, .dot()은 행렬 간의 곱셈을 수행한다. X_T.dot(X_matrix)는 독립변수들의 제곱합 및 교차곱 행렬인 $X^T X$를 형성하고, 이를 역행렬 처리한 후 $X^T y$와 곱함으로써 OLS 잔차 제곱합을 최소화하는 수학적 최적해 β 가중치들을 단 한 줄의 행렬 연산으로 정확하게 계산해 낸다.

  이 공식을 통해 도출된 가중치를 가상 학생의 시나리오 조건에 행렬 곱셈으로 대입하면 아래와 같은 단일 예측치를 얻을 수 있다.

```
8 # 3.정규방정식 직접 구현: 베타 = (X^T * X)^-1 * X^T * y
9 X_T = X_matrix.T
0 # np.linalg.inv: 역행렬을 구하는 기본 수학 연산이다.(해당과정에서 알고리즘 라이브러리를 사용하지 않음.)
1 beta = np.linalg.inv(X_T.dot(X_matrix)).dot(X_T).dot(y_values)
```

- [핵심 코드 2] 가상 학생 조건 대입을 통한 단일 선형 예측
  최적화된 회귀계수 벡터 beta 와 가상 학생의 조건인 target_matrix([1, 1.5, 30, 11])를 내적(Dot Product)하여 최종 선형 기댓값을 계산한다.
  연산결과, OLS 단일 예측 점수는 **"10.29 점"**으로 계산되었다[2]. 이 점수는 과락 기준인 8 점보다 명백히 높다. 따라서 선형회귀 분석만을 신뢰할 경우, 고위험군 시나리오 환경에 있는 학생은 최종시험에서 평균적으로 과락 당하지 않을 거라는 결론이 도출된다.

```
13 # 4. 단일 예측 점수 구하기(다중회귀분석 수치)
14 target_matrix = np.array([1, scenario_studytime, scenario_absences, scenario_G1])
15 base_prediction = target_matrix.dot(beta)
```

```
수동 구현 OLS 단일 예측 점수: 10.29점
오차 표준편차: 1.42점
```

[그림 1] 다중회귀분석의 최종성적 예측값

[2] [그림 1] 참고

- [핵심 코드 3] 오차의 표준편차 사용
  실제 데이터값과 회귀식의 예측값 간의 차이인 잔차(Residual)의 표준편차 np.std(residuals)를 계산한 결과 **1.42 점**이 도출되었다. 이 1.42 점은 단순한 에러가 아니라 시험 난이도나 당일 컨디션 등 선형 모델이 설명할 수 없는 '현실의 불확실성 두께'를 의미하며, 몬테카를로 시뮬레이션의 무작위 노이즈 주입을 위한 핵심 통계적 파라미터로 사용된다.

```
18 # 5. 오차 표준편차 구하기
19 all_predictions = X_matrix.dot(beta)
20 residuals = y_values - all_predictions
21 error_std = np.std(residuals)
```

3.2. 숄레스키 분해와 공분산 난수 생성

몬테카를로 시뮬레이션에서 가상의 학생 10,000 명을 복제할 때, 학습 시간과 결석 횟수, 1 학기 성적을 각각 완전히 독립적인 랜덤 난수로 생성하면 현실성이 결여된다. 이 부분에 대해 현실적으로 생각해보자. 현실에서는 공부를 잘하는 학생은 일반적으로 학습시간도 많을 거고, 출석률도 좋을 것이다. 이러한 현실적인 상황을 통제한 후, 분석을 진행하는 것이 훨씬 유의미하다. 숄레스키 분해는 이러한 변수들 간의 일정한 '상관관계'를 반영해주는 역할을 한다. 이를 사용하지 않으면, "주당학습시간은 1 시간이고, 결석률은 70%, 그런데 이전시험성적은 만점"인 학생이 생성될 수 있다.

이러한 상관관계를 유지한 채 다변량 정규분포 난수를 생성하기 위해, 변수들의 공분산 행렬을 하삼각행렬 L과 그의 전치행렬 L^T의 곱으로 분해하는 숄레스키 분해 공식을 코드로 수동 구현하였다.

- [핵심 코드 4] 숄레스키 분해를 통한 하삼각행렬(L) 수동 루프 구현

입력 행렬 A 는 독립변수들의 실제 공분산 행렬이다. 이중 루프를 돌며 대각 원소(i == j)일 때는 기존 분산에서 이전 변수들의 기여도를 제외한 값에 제곱근을 취하고, 비대각 원소일 때는 잔여 공분산을 대각 원소로 나누어 하삼각행렬 L 을 쌓아 올린다.

이렇게 얻은 L 행렬은 가상 학생을 만들 때 중요한 필터 역할을 한다. 서로 연관이 없는 독립적인 표준정규난수 행렬 Z의 왼쪽에 이 하삼각행렬 L 을 곱해주면($L \times Z$), 난수들이 실제 데이터가 가진 변수 간 상호 의존성(상관관계)을 완벽하게 흡수하여 결합된 형태의 다변량 구조적 난수로 변환된다.

```python
# 1. 수작업 Cholesky 분해 함수 정의 (라이브러리 미사용)
def manual_cholesky(A):
    n = len(A)
    L = np.zeros((n, n))
    for i in range(n):
        for j in range(i + 1):
            sum_k = sum(L[i][k] * L[j][k] for k in range(j))
            if i == j:
                L[i][j] = np.sqrt(A[i][i] - sum_k)
            else:
                L[i][j] = (A[i][j] - sum_k) / L[j][j]
    return L

# 2. 공분산 행렬 계산 및 수작업 함수 적용
cov_matrix = X.cov().values
L_matrix = manual_cholesky(cov_matrix)
```

위 과정을 마친 후, 시뮬레이션 횟수를 10,000 회로 지정하여 독립난수를 생성하였다. 이렇게 해서 생성된 10,000 개의 가상 학생 데이터를 목차 3.1 의 [핵심코드 2]에서 다중회귀분석의 단일예측 수치를 구하기 위해 사용한 수식에 대입하였다. 이 과정을 통해 10,000 명의 최종성적 데이터를 얻었다.

```
# 3. 독립 난수(Z) 생성 및 현실 변동성(L) 부여
Z = np.random.normal(0, 1, (3, sim_count))
scenario_mean = np.array([scenario_studytime, scenario_absences, scenario_G1]).reshape(3, 1)

virtual_students = scenario_mean + L_matrix.dot(Z)
virtual_students = virtual_students.T

# 4. 가상 학생들의 예측 점수 계산 (3번 셀에서 구한 beta 사용)
virt_X_matrix = np.c_[np.ones((sim_count, 1)), virtual_students]
predicted_G3 = virt_X_matrix.dot(beta)
```

3.3. 시뮬레이션 루프 및 시험 당일의 변동성 주입

그러나 10,000 개의 데이터를 그대로 사용하지 않는다. 목차 3.1 의 [핵심코드 3]에서 구한 오차의 표준편차를 이용하여, 오차항을 10,000 개의 데이터에 임의적으로 더해주었다. 이를 통해 시험 당일에 발생할 수 있는 환경적 불확실성을 나타내었다.

- [핵심 코드 5] 회귀 예측값에 시험 당일 불확실성(Residual Noise) 결합
  np.random.normal(0, error_std, sim_count)를 통해 OLS 모델의 실제 오차 표준편차(1.42 점)를 표준편차로 삼고 평균이 0 인 정규분포 난수 10,000 개를 생성한다. 이를 선형 예측 점수인 predicted_G3 에 결합함으로써, 동일한 조건의 가상 학생이라도 시험 당일의 사소한 변수로 인해 점수가 위아래로 흔들리는 현실적인 상황을 완벽히 재현해 낸다. 연산 후 점수의 유효 범위가 성적 시스템의 한계인 0 점~20 점을 벗어나지 않도록 np.clip() 연산 처리를 추가하여 데이터 정밀성을 보정하였다.

```
# 5. 당일의 불확실성(오차) 추가 및 점수 클리핑 - 3번 셀에서 구한 오차 표준편차 사용
final_noise = np.random.normal(0, error_std, sim_count)
simulated_scores = predicted_G3 + final_noise
simulated_scores = np.clip(simulated_scores, 0, 20)
```

3.4. 과락 확률 계산 및 대수의 법칙 검증

10,000 개의 최종 모의 성적 분포가 완성되면, 각 시뮬레이션 인덱스별로 과락 여부를 연산하고 점진적으로 확률이 수렴하는 과정을 추적한다.

- [핵심 코드 5] 벡터화 연산을 통한 누적 과락 확률 및 수렴도 계산

  8 점 미만인 조건에 부합하면 True(1), 아니면 False(0)의 배열을 생성한 후 np.cumsum() 함수를 통해 1 번째 실험부터 10,000 번째 실험까지 누적해서 발생한 과락자 수의 합계를 구한다. 이를 현재까지 진행된 실험 횟수(np.arange)로 나누어 백분율을 취함으로써, 시뮬레이션 횟수가 거듭됨에 따라 과락 확률이 통계적으로 어떻게 안정화되어 가는지 흐름을 추적할 수 있도록 행렬화 하였다.

  그리고 10,000 번의 몬테카를로 반복 시뮬레이션을 수행한 결과, 최종 과락 확률은 24.14%로 집계되었다.[3]

```
35 # 수렴 그래프를 위한 누적 확률 계산
36 failures = (simulated_scores < fail_threshold).astype(int)
37 cumulative_failures = np.cumsum(failures) # N번째까지의 과락자 누적 합계
38 n_trials = np.arange(1, sim_count + 1)
39 convergence_probs = (cumulative_failures / n_trials) * 100 # N번째까지의 누적 확률
```

```
최종 과락 확률: 24.14%
```

[그림 2]시뮬레이션을 통해 밝혀낸 과락 확률

[3] [그림 2] 참고

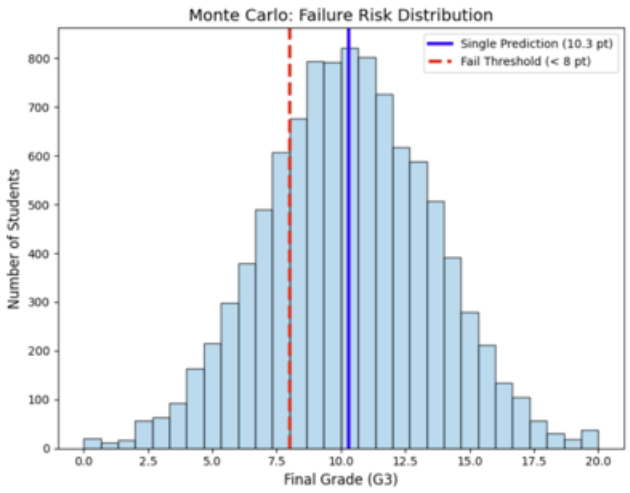
4. 시각화 및 결과 해석

시뮬레이션을 통해 도출된 데이터의 구조와 의미를 파악하기 위해 matplotlib 을 이용한 시각화 분석을 수행하였다.

4.1. 성적 분포 히스토그램

[그림 3]은 최종과락확률의 정규분포와 다중회귀분석의 단일예측 수치를 나타낸 그래프이다. 단일예측 평균 값인 10.29 점(파란색 실선)을 중심으로 성적이 좌우 대칭의 종 모양인 정규분포 형태로 넓게 퍼져 있음을 보여준다.

여기서 가장 주목해야 할 구간은 낙제 기준선인 8 점(빨간색 점선)의 좌측 면적이다. 단일 회귀분석 결과인 10.29 점만 보았을 때는 전혀 감지할 수 없었던 '과락 위험 군집'이, 시뮬레이션을 통해 선명하게 드러났다. 8 점 미만의 과락 구역에 속한 가상 학생은 전체 10,000 명 중 2,414 명으로, 면적 비율상 정확히 24.14%를 차지한다. 즉, 이 고위험군 시나리오에 처한 학생은 대략 4 명 중 1 명꼴로 실제 낙제를 맞이하게 된다는 강력한 경고를 통계적 분포로 시각화한 것이다.

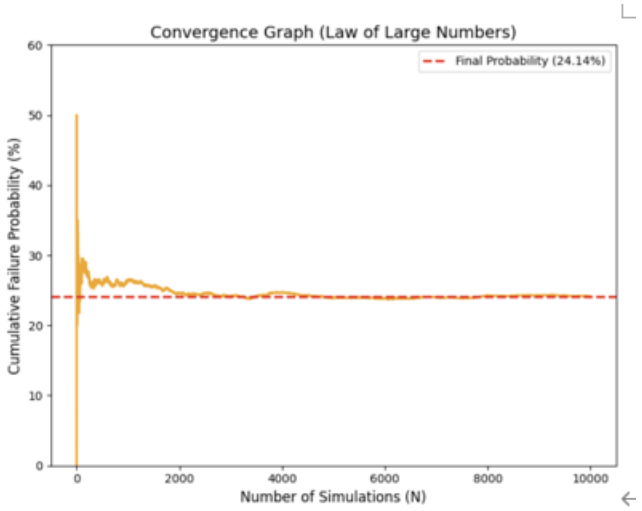


[그림 3] 최종 과락 확률 시각화 그래프

4.2. 대수의 법칙 수렴 시각화

[그림 4]는 몬테카를로 시뮬레이션의 수학적 타당성과 신뢰도를 대변한다고 볼 수 있다. 시행 횟수(N)가 1,000 회 미만인 초반 구간에서는 무작위 난수의 무작위성 때문에 주황색 누적 확률 선이 위아래로 심하게 요동치며 불안정한 모습을 보인다.

그러나 시행 횟수가 5,000 회를 넘어 10,000 회에 도달할수록 대수의 법칙에 의해 우연에 의한 왜곡이 상쇄되며 변동 폭이 극도로 미미해진다. 최종적으로는 목표선인 **24.14%**(빨간색 수평 점선)에 완전히 수렴하여 수평선을 그리게 된다. 이 수렴 현상은 우리가 얻은 24.14%라는 리스크 수치가 단순한 일회성 요행이나 난수 에러가 아니라, 주어진 확률 모형 하에서 도출할 수 있는 매우 안정적이고 신뢰할 수 있는 통계적 지표임을 입증한다.



[그림 4] 대수의 법칙을 통한 확률 수렴 그래프

5. 결론 및 제언

5.1. 핵심 결론 및 시사점

본 연구는 OLS 다중회귀분석의 단일 선형 예측이 가질 수 있는 맹점을 지적하고, 이를 몬테카를로 시뮬레이션과 결합하여 교육 데이터 내의 불확실성을 성공적으로 가시화하였다.

회귀 모델은 고위험군 학생의 기말 성적을 과락 기준보다 안전한 **10.29 점**으로 단정 지었으나, 이는 데이터 이면에 내재된 변동성을 누락한 결과였다. 반면, 몬테카를로 시뮬레이션을 통해 시험 당일의 오차와 변수 간 공분산을 복원한 결과, 이 학생에게는 무려" **24.14%"의 잠재적 과락 확률**이 숨겨져 있음이 드러났다.

전통적 분석이 놓치기 쉬운 최악의 시나리오를 정량적 확률로 바꾸어 냄으로써, 통계학적 방법론이 어떻게 현실의 리스크 관리와 결합될 수 있는지를 명확히 증명하였다.

5.2. 연구의 한계점

- 변수 선택의 제한성: 다중공선성을 방지하고 시뮬레이션의 직관성을 위해 원본 데이터셋의 33 개 변수 중 오직 3 개(studytime, absences, G1)만을 모델에 사용하였다. 학생의 주거 형태, 부모의 교육 수준, 알코올 섭취량 등 성적에 영향을 미칠 수 있는 타 변수들이 통제되어 회귀 모형 자체의 설명력(R-squared)에 한계가 존재한다.
- 정성적 요인의 계량화 한계: 시험 당일의 심리적 압박감, 문제의 주관적 난이도, 교우 관계의 변화 등 숫자로 환산하기 어려운 비정형 요인들은 단순히 백색 잡음(White Noise) 형태의 정규분포 난수로 대체되었으므로 실제 현실의 복잡한 인과관계를 완벽히 투영했다고 보기는 어렵다.
- 시나리오 의존성: 본 분석에서 도출된 24.14%라는 위험도는 분석가가 설정한 특정 조건(공부시간 1.5, 결석 30 회)에 종속된다. 입력 시나리오가 조금만 바뀌어도 확률이 민감하게 변동하므로 절대적인 수치로 오용해서는 안 된다.

5.3. 향후 확장 방향 및 실무적 의의

해당 결과는 실제 교육 현장에서 '학업 위기 조기경보 시스템'으로 사용할 수 있는 가능성이 존재한다.

1. 다변량 공분산 모형의 고도화: 학기 중 수집 가능한 중 성적(G2), 가구 내 인터넷 접근성(internet), 과거 낙제 횟수(failures) 등을 공분산 행렬 연산과 숄레스키 분해 루프에 추가 반영하여, 복합적인 생활 환경 패턴까지 흡수한 초정밀 가상 학생 표본을 구축한다.
2. 개인 맞춤형 리스크 대시보드 자동화: 학과 내 전체 학생의 실시간 출석률과 과제 제출 빈도 데이터를 파이썬 파이프라인과 연동한다. 학생의 상태가 변할 때마다 본 모델의 행렬 연산 루프가 자동으로 실행되어, 개별 학생별 "실시간 기말고사 과락 위험도(%)"를 대시보드에 실시간 업데이트한다.
3. 선제적 교육 개입 정책 수립: 상담 센터 및 지도 교수는 단일 성적 예측치에 의존해 방치하는 실책을 범하지 않고, 시뮬레이션이 경고하는 과락 확률(예: 위험도 20% 초과)을 기준으로 고위험군 학생들을 선제적으로 선별할 수 있다. 기말고사를 치르기 전 주차에 멘토링 프로그램을 강제로 매칭하거나 맞춤형 학업 클리닉을 제공하는 등, 데이터 기반의 과학적이고 예방적인 교육 복지 행정을 실현하는 데 기여할 수 있을 것이다.

6.참고문헌

- Glasserman, P. (2003). Monte Carlo Methods in Financial Engineering. Springer. (Cholesky 분해 및 다변량 샘플링 이론 참고)

- https://archive.ics.uci.edu/dataset/320/student+performance(사용한 데이터 출처)